Dakar Institute of Technology | Outils statistiques

Modélisation Prédictive de la Survie dans le Cancer du Sein



Jeu de données METABRIC : audit, prétraitement et préparation à la comparaison de modèles

Presenté par Ouleymatou Sidy KANE

Source : Kaggle

Contexte et objectif

Données

METABRIC : 2509 patientes, 34 variables cliniques et moléculaires.

Objectif

Prédire si une patiente décède de la maladie (1) ou non (0).

Démarche

Préparer un jeu propre, puis comparer plusieurs modèles (SVM, arbres).

Vue d'ensemble de la démarche



Audit

Dimensions, types, valeurs manquantes, doublons

Nettoyage

Colonnes inutiles ou redondantes retirées

Cible

Décès par la maladie (1) ou vivante (0)

Split

Train/test stratifié 80/20

Prétraitement

Imputation, log, encodage

Étape suivante : comparaison de modèles (SVM et arbres) sur ces mêmes données préparées

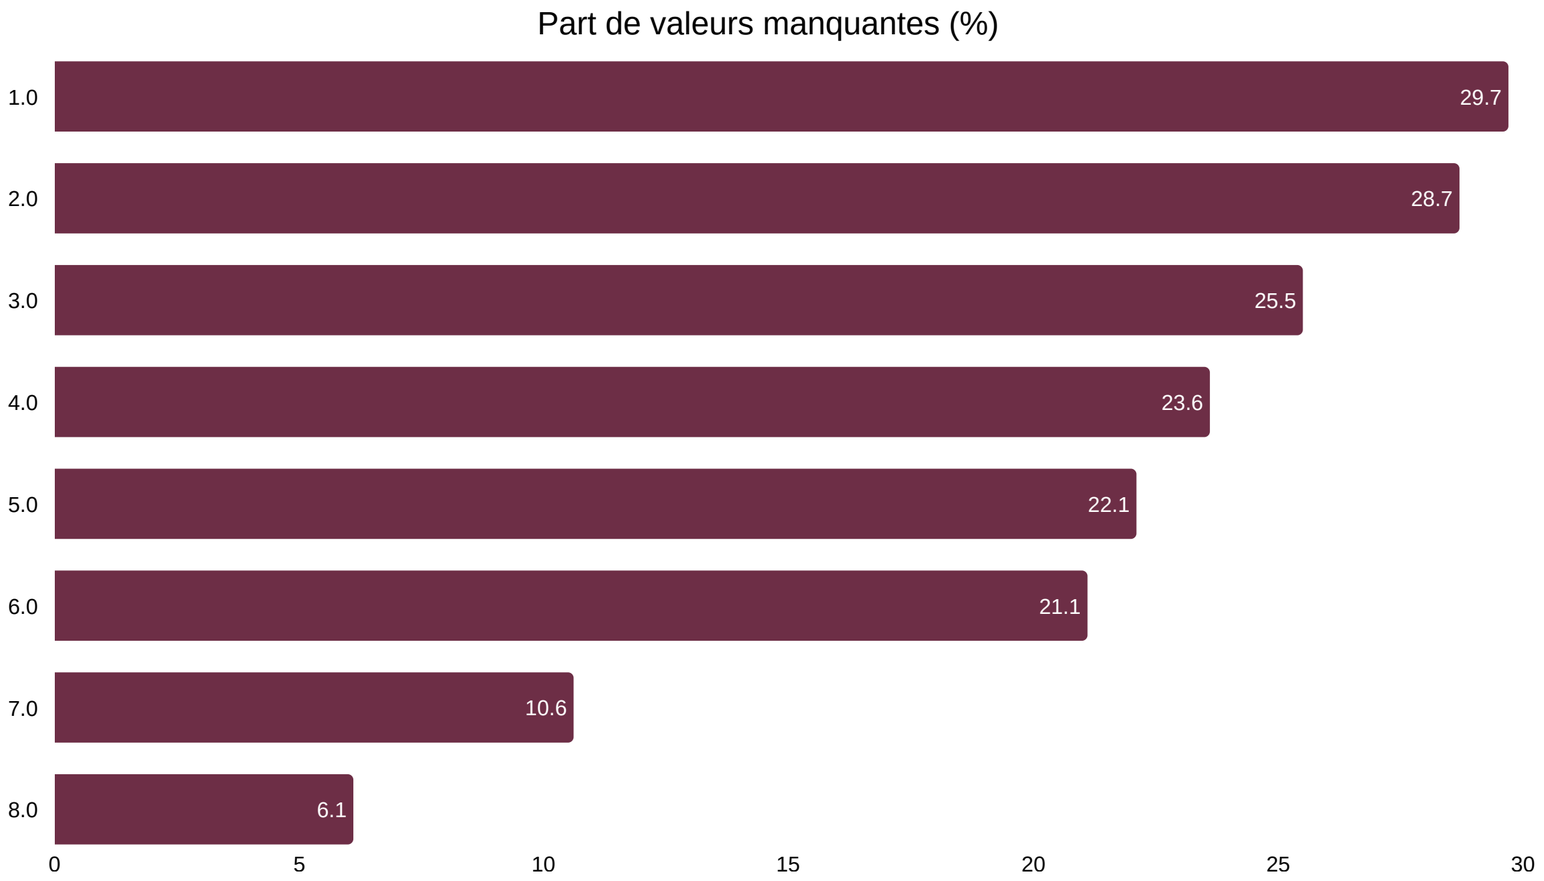
Audit et nettoyage des données

Audit initial

- 2509 patientes et 34 variables
- 5 doublons retirés après suppression de l'identifiant
- ER IHC et ER Status concordent à 94,7 %
- Faute de frappe « Positve » corrigée

Colonne retirée	Raison
Patient ID	Identifiant
Cancer Type, Sex	Quasi constantes
ER status (IHC)	Redondant avec ER Status
HER2 status (SNP6)	Redondant avec HER2 status
Oncotree Code	Redondant avec Cancer Type Detailed
Nottingham index	Redondant (option DROP_NPI)

Valeurs manquantes avant traitement



529

patientes quasi vides, mêmes lignes sur tout le bloc clinique

21 %

du fichier sans statut vital : retiré avec la cible

< 11 %

de manquants pour la plupart des variables restantes

De 2509 à 1483 patientes

2509
patientes dans le fichier

2504
après 5 doublons retirés

1980
avec un statut vital connu

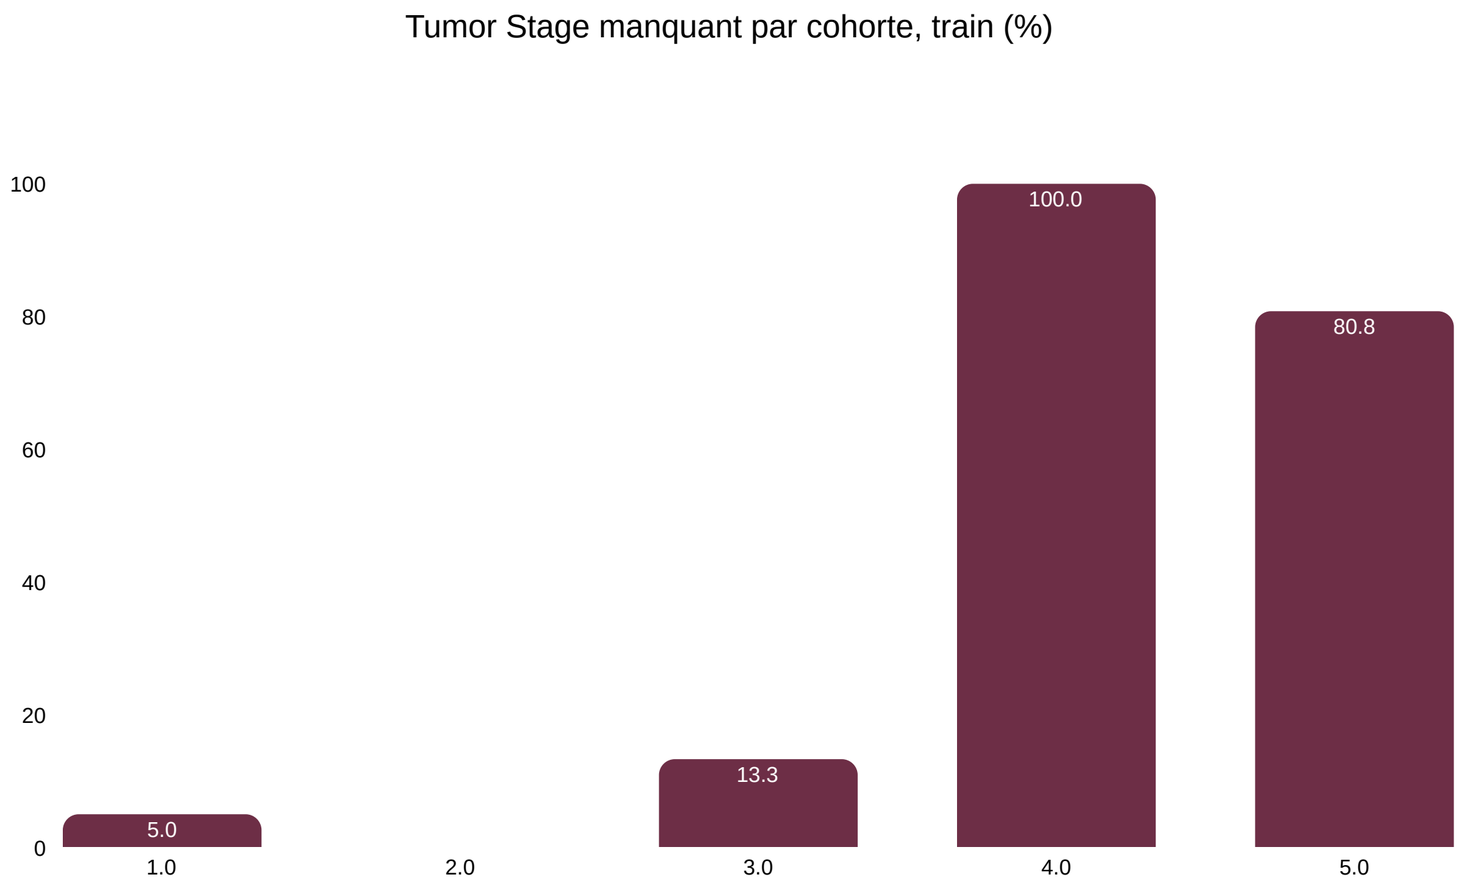
1483
hors décès d'une autre cause (497)

Colonnes retirées pour éviter la fuite de données

- Statut vital
- Survie globale (mois)
- Statut de survie globale
- Statut sans récidive
- Sans récidive (mois)

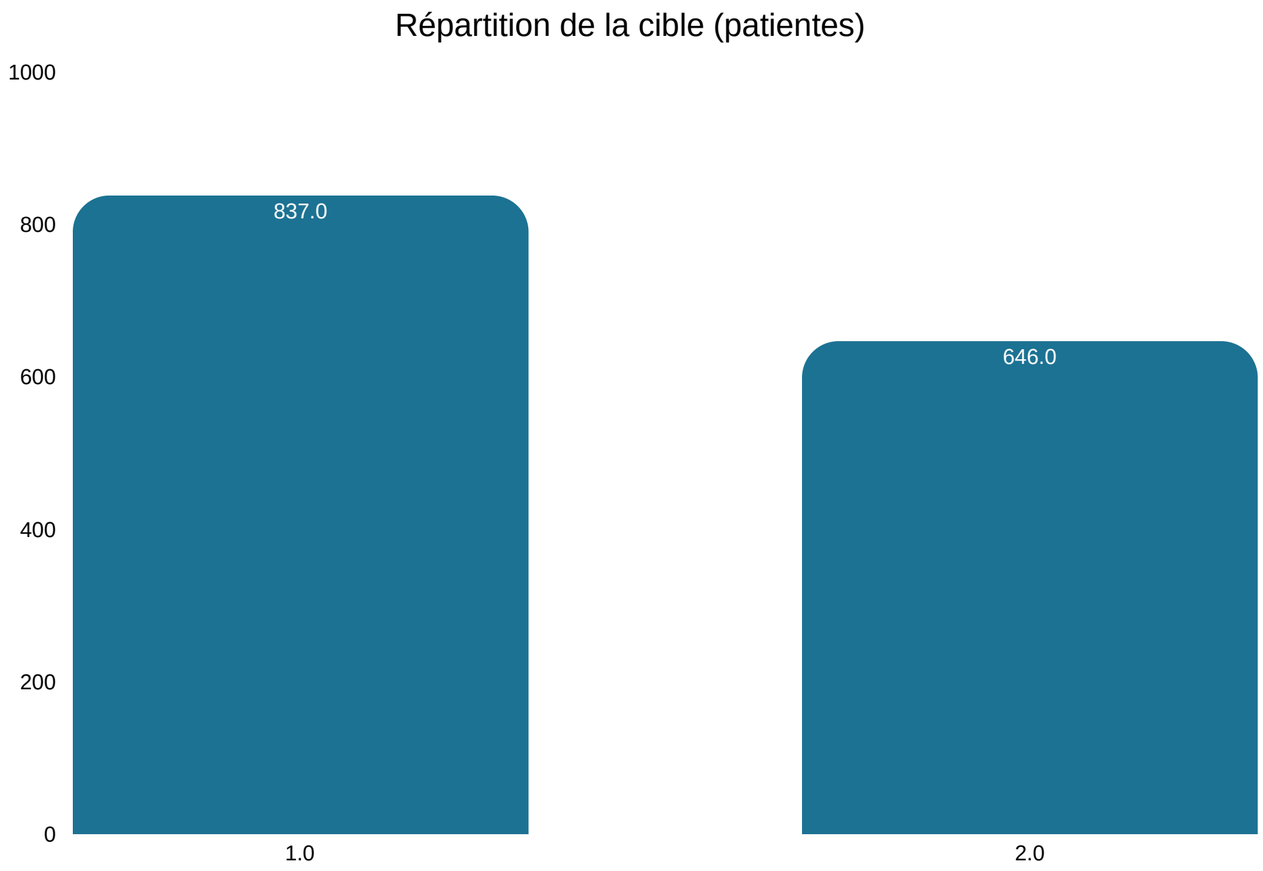
Elles décrivent déjà l'issue : les garder reviendrait à donner la réponse au modèle.

Des manquants liés à la cohorte



- Le stade n'a pas été relevé dans les cohortes 4 et 5 : les trous ne sont pas aléatoires
- Latéralité : 35,1 % de manquants dans la cohorte 4 seulement
- Mutation Count : 16,6 % de manquants dans la cohorte 1
- Tester le modèle avec et sans Cohort

Une cible assez équilibrée



56,4 %

de vivantes : le niveau de base à battre

1186 / 297

patientes en train / test, split stratifié, graine 42

Évaluer avec ROC-AUC, AUC-PR, rappel et F1, pas seulement l'accuracy.

Typage et variables créées

Numériques asymétriques

Log1p : taille tumorale, ganglions positifs, nombre de mutations

Numérique linéaire

Âge au diagnostic, sans transformation

Ordinales

Grade, stade tumoral, cellularité (Low < Moderate < High)

Binaires

Chimiothérapie, hormonothérapie, radiothérapie, statuts ER, PR, HER2

Nominales

Chirurgie, sous-type PAM50, cohorte, cluster intégratif, ménopause

Variables créées

Triple négatif (271 patientes, 18,3 %) et atteinte ganglionnaire (≥ 1)

Prétraitement : SVM et arbres

prep_svm

SVM et modèles linéaires

- Standardisation activée
- Log, imputation, encodage
- Échelles comparables entre variables

prep_trees

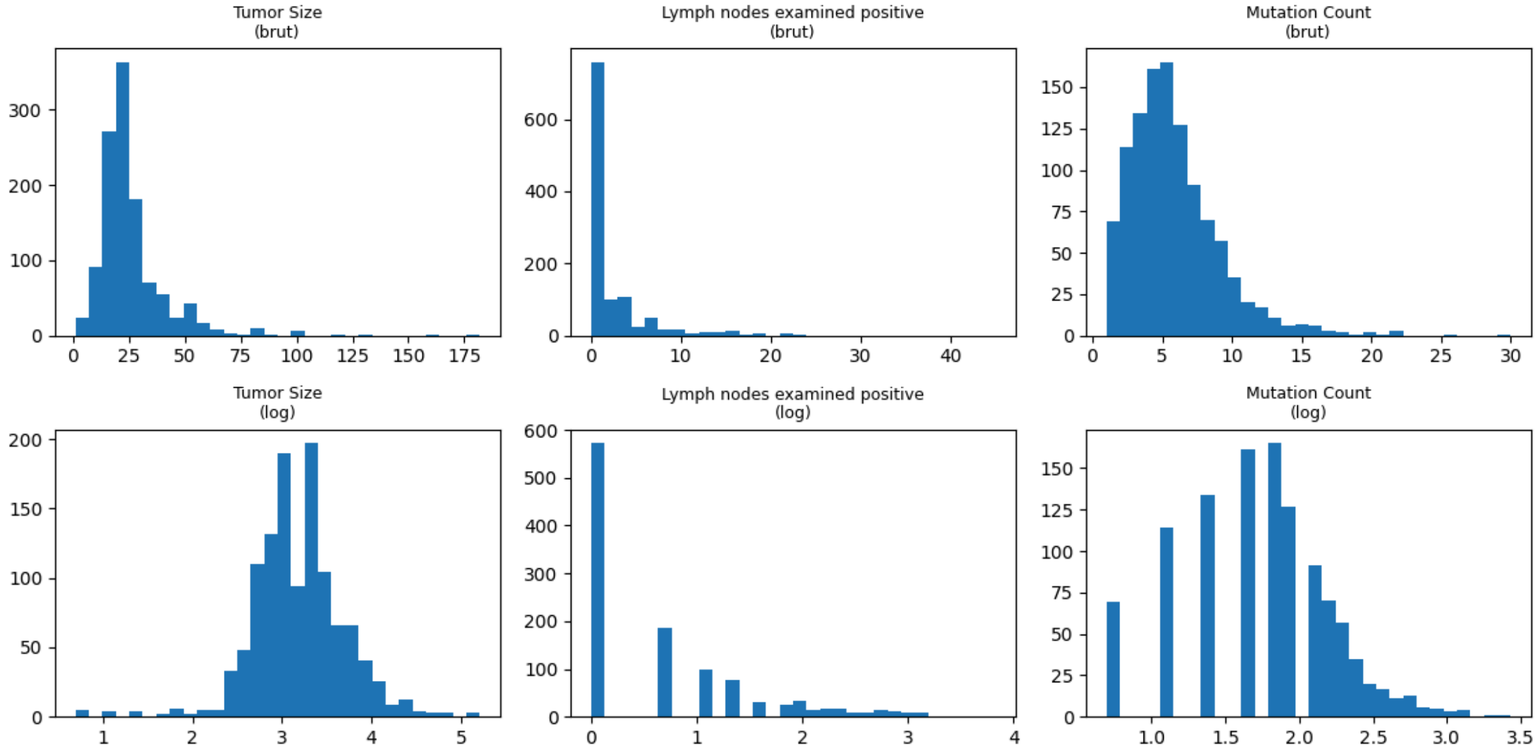
Arbres et forêts

- Pas de standardisation
- Mêmes imputations et encodages
- Insensibles aux échelles

Imputation et encodage : 64 variables en sortie, 0 valeur manquante

Numériques : médiane (défaut), KNN ou itérative, avec indicateur de valeur manquante. Catégorielles manquantes : « Unknown ». Modalités rares (< 2 %) regroupées.

Asymétrie et transformation log



- Taille tumorale : quasi en cloche après log
- Mutations : plus symétrique
- Ganglions : un pic à 0 demeure, d'où la variable binaire créée

Les valeurs extrêmes (tumeur de 180 mm, 45 ganglions, 80 mutations) sont conservées : médicalement plausibles.

Corrélations de Spearman (train)

	Âge	Taille	Gangl.	Mutat.	Grade	Stade
Âge	1,00	0,11	0,02	0,00	-0,11	0,09
Taille	0,11	1,00	0,33	0,04	0,17	0,58
Gangl.	0,02	0,33	1,00	-0,03	0,19	0,69
Mutat.	0,00	0,04	-0,03	1,00	0,08	-0,03
Grade	-0,11	0,17	0,19	0,08	1,00	0,20
Stade	0,09	0,58	0,69	-0,03	0,20	1,00

Aucune corrélation au-dessus de 0,8 : pas de multicolinéarité sévère.

0,69

Stade et ganglions : lien attendu, le stade en dépend

0,58

Stade et taille tumorale

< 0,1

Mutations : indépendantes des autres variables



Limites

- Cible binaire : la durée de suivi est ignorée
- Cohorte : effet de centre, stade absent selon la cohorte
- Environ 18 patientes par variable en train

Dépister tôt, c'est mieux soigner



Connaître son corps

Repérer toute boule ou changement du sein et consulter sans attendre.



Se faire dépister

Parler à son médecin du dépistage adapté à son âge et à ses antécédents.



Agir au quotidien

Activité régulière, poids stable, alcool limité, pas de tabac.

Analyse statistique à visée pédagogique : elle ne remplace pas un avis médical.